

# 주요 재무변수들과 그 변화율을 이용한 기업신용평가 예측모델

이성우 <sup>a</sup> 서용무 <sup>b</sup>

<sup>a</sup> 이성우

Anam-dong 5-ga, Seongbuk-gu, Seoul 136-701, Korea  
Tel: +82-10-2101-8445, E-mail: swlee443@gmail.com

<sup>b</sup> 서용무

Anam-dong 5-ga, Seongbuk-gu, Seoul 136-701, Korea  
Tel: +82-2-3290-1945, Fax: +82-2-922-7220, E-mail: ymsuh@korea.ac.kr

## Abstract

기업신용평가는 회사의 신용도 및 부도율 예측의 필요한 정보를 제공하며, 금융산업의 효율과 안정을 위해 필수적인 요소이다. 2007년의 글로벌 경제 위기 이후, 전문 신용평가사에 의해 결정되는 등급별 기업신용평가는 보다 더 객관적이고 보다 더 정확한 평가방식의 적용이 필요하게 되었다. 본 연구에서는 기업신용평가에 필요한 변수로 중요한 재무정보와 이들의 연도별 변화율을 변수로 선정 한 후, decision tree(J48), naïve bayesian, random forest 등의 다양한 마이닝 알고리즘을 적용하여 신용평가모델을 구축하였다.

이를 위해 본 연구에서는 Wharton Research Data Services에서 2011년부터 2013년까지 S&P로부터 신용등급을 받은 북미지역 1,158개 기업의 신용등급과 재무정보를 받아, 세 가지 실험을 실시하였다. 먼저, 주요 재무정보들의 연도별 변화율이 신용평가에 긍정적인 영향을 미치는지 알아보기 위해, 기존 연구에서 사용한 변수들과 함께 이들의 2년간의 변화율을 가지고 평가모형을 구축하여 기존 연구에서의 평가모형과 그 정확도를 비교한 결과 재무정보들의 변화율이 평가에 긍정적인 영향을 미치는 것으로 확인 되었다. 다음으로, 기존 연구에서 중요하게 쓰인 재무변수 중 32개의 후보변수를 선정한 후 평가모형을 구축하여 그 정확도를 비교한 결과 15개의 변수를 사용하여 구축한 평가모형이, 본 연구에서 참조한 기존 연구에서 구축한 평가모형보다 예측정확도가 좋았다. 마지막으로, 앞에서 선정한 15개의 변수와 이들의 2년간의 변화율 변수를 사용한 결과 가장 좋은 예측률을 보이는 평가모형을 구축할 수 있었다.

결론적으로, S&P에서 받은 데이터를 사용하여 실험한 결과, 주요 재무변수들과 이들의 2년간의 변화율이 기업신용평가에 유익하게 사용될 수 있음을 확인하였다.

**Keyword:** 기업신용평가; 데이터마이닝; Bagging;

## RandomForest

## Introduction

기업신용평가는 회사의 신용도 및 부도율 예측의 필요한 정보를 제공하며, 금융산업의 효율과 안정을 위해 필수적인 요소이다. 채권 발행 시 신용평가 관련 법규에 의하여 해당 기업은 전문 신용평가사의 평가를 받게 되어 있다. 그러나, 2007년의 글로벌 경제 위기 시에 즈음하여 전문 신용평가사로부터 높은 신용등급을 받은 기업들이 갑자기 파산하기도 하였으며, 전문 신용평가사들은 시장점유율을 높이기 위하여 등급 부풀리기 등의 부조리를 행하기도 하였다. 따라서, 기업의 신용평가를 신뢰할 수 있도록 하기 위하여 보다 더 객관적이고 보다 더 정확한 평가 방식이 필요하게 되었다.

그 동안 기업의 신용 예측을 정확하게 하기 위한 모형 개발에 관한 많은 연구가 진행되어 왔지만, 기업의 신용평가가 경제에 미치는 영향이 지대하고, 금융산업의 발전을 위하여, 또한 투자자들을 보호하기 위하여, 앞으로도 그런 연구를 할 가치는 충분하다고 할 수 있다.

기업의 신용평가 등급은 통상 AAA 등급에서 시작하여 D 등급까지 많은 평가 등급(S&P의 경우 22등급)이 있어 예측모형을 통하여 많은 등급을 정확하게 예측하기란 매우 어렵다. 그러므로 본 연구에서는 투자자들을 보호하기 위하여 전문 신용평가사들의 기준에 따라서 투자 안정(AAA to A-), 투자 가능(BBB+ to BBB-), 투자 불안(BB+이하) 등 3가지 등급으로 구분 하였다. 최대한 많은 기업의 자료를 이용하여 정확한 예측 모형을 개발하기 위하여 1,158개 기업의 3년치 재무정보를 수집하였다. 본 연구의 특징은 대부분의 정상 기업들은 재무 정보가 크게 변하기 않을 것이라는 가정 하에 주요 재무정보들의 변화율을 신용 평가 예측모형을 개발을 위한 변수로 추가한 점이다. 우리가 기대하였던 바대로, 주요 재무정보들의 변화율은 모형의 예측률을 높이는데 기여하였으며, 그 결과 구축된 모형의 예측률은 본 연구에서 참조하였던 기존의 연구에서 개발한 모형의

예측률을 증가하였다. 예측모형은 decision tree(J48), naïve bayesian, random forest 등의 다양한 마이닝 알고리즘을 적용하여 구축하였다.

### Literature review

기업신용등급을 예측하기 위한 다양한 연구들이 진행되었는데, 그 중 데이터 마이닝 기법을 적용한 신용등급 예측에 관한 연구들을 검토하였다.

Niklis 등의 연구에서는 Greek stock exchange로부터 수집한 총 1,314개의 회사들의 7개의 재무정보를 활용하여 기업부도위험을 예측하였다. 이 연구에서는 Kolmogorov-Smirnov (KS) distances를 이용하여 부도위험과 선정변수의 양(+) 또는 음(-)의 영향을 파악하였으며, Linear, RBF, additive SVM과 Black-Scholes-Merton 모델을 구축하였는데, 79%의 예측정확도를 나타냈다 (Niklis et al., 2014).

Zhong 등의 연구에서는 기존 연구에서 많이 사용된 4개의 learning algorithms 인 BP, ELM, I-ELM, SVM의 효과를 검증하기 위해 SNFLs 알고리즘을 위의 4개의 알고리즘에 적용해서 Reliability (accuracy, overfitness, error distribution)와 Rating distribution으로 검증하였다. 데이터로는 Moody's Investor Services(MIS)와 S&P사의 두 가지 평가등급과 Financial statements의 보고서를 통해 8가지 재무정보를 수집하였으며, SVM은 Rating distribution에서 그리고 ELM과 I-ELM은 Reliability에서 각각 가장 우수한 알고리즘으로 나타났다 (Zhong et al., 2014).

Kim 등의 연구에서는 Partitioning method (One-Against-The-Next, one-Against-Followers), 와 Fusing method (Forward and Backward)를 적용하여 4가지 단계로 구축한 Ordinal Multi-class Support Vector Machine(OMSVM)을 제안하였다. 이 연구의 데이터로는 한국의 1,295개 회사들을 대상으로 14개의 재무변수를 선정하여 사용하였으며, 구축된 모델은 67.98%의 예측정확도를 나타냈다 (Kim and Ahn, 2012).

Ogut 등의 연구에서는 터키은행의 재무안정평가등급이 그들의 신용평가사에서 받은 평가등급과 일치하는지를 알아보기 위해 통계적 기법인 multiple discriminant analysis(MDA)와 ordered logistic regression(OLR)을 데이터 마이닝 기법인 support vector machine(SVM)과 probabilistic neural network(PNN)의 알고리즘으로 서로 예측결과를 비교하였다. 데이터는 Moody's사의 신용등급과 Turkish Banks database로부터 받은 18개 은행 25개의

재무비율이 쓰여졌으며, MDA와 SVM에서 구축된 모델의 예측정확도가 서로 같은 65.11%로 가장 높게 나타났다 (Ogut et al., 2012).

Chen 등의 연구에서는 Factor Analysis(FA)와 Minimized Entropy Principle Approach (MEPA)에 각각 Rough Set theory(RS)를 함께 적용한 하이브리드 모델을 구축하였다. Fitch사의 신용등급과 37개의 변수로 구성된 1,950개 글로벌 은행의 데이터 셋을 사용하였다. FA와 RS의 하이브리드 모델의 경우 변수 6개를 사용하였을 때 79.29%의 예측정확도를 보였으며, MEPA와 RS의 하이브리드 모델의 경우 16개 변수를 사용하였을 때 82.14%의 예측정확도를 나타냈다 (Chen and Cheng, 2012).

Huang 등의 연구에서는 Support vector machine (SVM)과 Back propagation neural network (BNN) 알고리즘을 사용하였다. US(265 cases)와 Taiwan (74 cases) 의 데이터 셋에서 21개의 변수를 선정하였으며, 각각 80.38% (SVM)와 80.75% (BNN)의 예측정확도를 나타냈다 (Huang et al., 2004).

Ye 등의 연구에서는 random forests (RF)와 rough set theory (RST)를 결합한 hybrid KMV 모델을 구축하였다. 2,470개 Taiwanese 기업 데이터에 22개 변수를 선정하여 93.4%의 예측정확도를 나타냈다 (Ye et al., 2012).

Na 등의 연구에서는 재무정보의 유용성을 검증하기 위해 415개의 투자등급기업과 181개의 투기등급기업을 대상으로 신용평가사에서 주요 재무비율로 공시하는 35개의 재무비율을 선정하였다. 선정된 재무비율로 투자/투기 기업집단간 t-검정을 실시하여 9개의 주요 재무비율을 나타냈으며, logit 분석을 통해 9개의 주요 재무비율로 차기 년도의 신용평가 예측을 실시한 결과 90% 이상의 예측정확도를 나타냈다 (Na and Jin, 2003).

Lee 등의 연구에서는 판별분석을 통해 재무정보가 신용등급변경을 예측하는데 유용성이 있는지를 연구하였는데, 555개 기업과 25개의 재무비율을 데이터로 사용하였다. 한국의 외환위기 이후 신용평가사들은 투자적격등급 재무기준을 강화하였는데, 25개의 재무비율 중 재무기준 강화 이전과 강화 이후의 등급변경에 영향을 미치는 주요 재무비율을 판별분석을 통해 나타냈으며, 그들의 예측률은 각각 재무기준 강화 이전 63.92%와 강화 이후 72.75%의 예측정확도를 나타냈다 (Lee et al., 2004).

Table 1 - Credit rating Studies

Reference s	Method	Sample	Variables	Classes
Niklis et al. (2014)	SVM	1,314	7	2

Zhong et al. (2014)	BP, ELM, I-ELM, SVM, SNFLs	-	8	21의 등급을 1(excellent)부터 -1(poor)까지 재등급화함
Kim and Ahn (2012)	OMSVM	1,295	14	4
Ogut et al. (2012)	MDA, OLR, SVM, PNN	18	25	6
Chen and Cheng(2012)	FA-RS, MEPA-RS	1,950	37	5
Huang et al. (2004)	SVM, BNN	339	21	5
Ye et al. (2012)	KMV	2,470	22	3
Na and Jin (2003)	logit analysis	415	35	-
Lee et al. (2004)	discriminant analysis	555	25	-

## Methods

본 연구에서는 오픈소스 데이터 마이닝 툴인 WEKA 3.6.11을 사용하여 Decision tree(J48), Naïvebayesian, RandomForest 그리고 이들의 앙상블기법까지 다양한 classification 알고리즘을 이용해서 기업의 신용등급을 예측하기 위한 모델을 구축한 후, 기존의 연구 결과와 비교하였다. 데이터 마이닝의 통상적인 절차에 따라서, 데이터의 Balancing 작업을 하였고, wrapper 방식에 backward elimination 기법으로 변수를 선정하였으며, 데이터의 70%를 training dataset으로, 나머지 30%를 test dataset으로 사용하였다.

## Data

본 연구에서는 사용한 데이터의 출처는 Wharton Research Data Services이며, 이곳으로부터 받은 데이터에는 2011년부터 2013년까지 신용등급을 받은 북미지역 1,158개 기업의 Standard & Poor's(S&P) 신용등급과 재무정보를 포함하고 있다.

S&P가 평가한 기업(1,600기업 이상)들은 AAA부터 B-등급까지의 16개 등급으로 나누어져 있다. 기업의 신용을 16가지 등급 중 하나로 예측하기에는 어려움이 있다. 즉, 각 등급에 해당하는 기업의 수가 너무 불균형을 이루기 때문에 예측모형의 training이 제대로 이루어지지 않아 구축된 예측 모형의 정확도가 떨어질 수밖에 없다. 그래서, 전문 신용평가사의 투자기준에 따라서, 기업의 신용

등급을 투자안정(AAA to A-), 투자가능(BBB+ to BBB-), 투자불안(BB+이하) 3가지의 클래스로 구분하였고, 각 클래스에 속하는 기업의 수를 균등하게 386개로 조절하였다

Table 2에서 보듯이, S&P가 제공한 데이터를 가공하여 본 논문에서 참조한 여러 논문들에서 사용된 변수들을 포함하도록, 8개 범주의 32개 변수를 추출하였다. Table 2를 보면, 주요 재무변수 외에, 재무변수들 간의 비율을 나타내는 변수가 많음을 알 수 있다.

Table 2 – Categories and definitions of candidate financial variables

Variables	Category	Definition
X1	Size	Total assets in natural log
X2	Financial Structure	Net assets/ total debt
X3	Financial Structure	Quick ratio
X4	Financial Structure	Current assets/ shareholder equity
X5	Profitability	Return on total assets
X6	Profitability	Return on equities
X7	Profitability	Earnings per share
X8	Profitability	Gross Profit margin
X9	Profitability	Sales/total assets
X10	Leverage	Debt ratio
X11	Leverage	LT debt/Net assets
X12	Leverage	Total debts/cash equivalents
X13	Leverage	Retained earnings/total assets
X14	Leverage	Long-term debt leverage ratio
X15	Solvency	Interest expenses/sales
X16	Solvency	Equity/total assets
X17	Solvency	Working capital/total assets
X18	Solvency	Total liabilities/cash
X19	Solvency	(Current assets-Inventory)/ Current liabilities
X20	Solvency	Operating cash inflow/ current liabilities
X21	Solvency	Interest coverage ratio
X22	Management ability	Inventory turnover ratio
X23	Management ability	Sales/ total cash reserves
X24	Liquidity	Sales/short-term liabilities
X25	Liquidity	Net working capital/sales
X26	Liquidity	Net working capital/total assets
X27	Liquidity	Current ratio
X28	Cash	Cash reserves/current liabilities
X29	Cash	Cash /total debts
X30	Cash	Cash /total assets
X31	Cash	Cash/Inventory
X32	Cash	Cash flow from operating activity

## Experimental design

보다 정확한 예측을 가능케 하는 신용평가모형을 구축하기 위하여 세가지 실험을 하였다.

1) 주요 재무변수들의 연도별 변화율이 신용평가에

긍정적인 영향을 미치는가? (Tables 5 참조)

- 2) 어떤 재무변수들을 사용하여 기업의 신용평가 예측모형을 구축하여야 하는가?
- 3) 실험 2)에서 선정한 변수들과 그들의 2년간의 변화율을 사용하여 신용평가모형을 구축할 경우, 그 예측도는?

Table 3 – Variables in Niklis et al. (2014)

	Variables
1	Gross profit/sales
2	Earnings before taxes/total assets
3	Total liabilities/total assets
4	Interest expenses/sales
5	Current assets/short-term liabilities
6	Sales/short-term liabilities
7	(Accounts receivable x 365)/sales

Table 4 - Variables in Zhong et al. (2014)

	Variables
1	Debt ratio
2	Current ratio
3	Quick ratio
4	Net profit margin
5	Gross profit margin
6	Return on total assets
7	Net profit / Total assets
8	EBIT / Sales

## Result

첫 번째 실험에서의 결과는 Table 5에 요약하였다. Niklis et al. (2014) 연구에서 사용한 변수들(Table 3)로 RandomForest로 Bagging을 하였을 경우 모델의 정확도는 62.39%인 반면, 이 변수들과 이들의 2년간의 변화율을 함께 사용하여 구축한 같은 모델의 정확도는 63.87%이었다. 마찬가지로, Zhong et al. (2014) 연구에서 사용한 변수(Table 4)들로 RandomForest로 Bagging을 하였을 경우 모델의 정확도는 65.72%인 반면, 이 변수들과 이들의 2년간의 변화율을 사용하여 구축한 같은 모델의 정확도는 67.32%이었다. 각각 사용한 논문 변수에 따라 결과의 차이가 나타나지만, 재무변수들의 다년간 변화율을 신용평가모형구축에 사용할 경우 대부분의 예측정확도가 상승하였음을 확인할 수 있었다.

Table 5 – Accuracy of the first experiment

	Decision Tree	Naïve Bayesian	Random Forest
Table 3의 변수들	54.87%	42.05%	59.68%
Table 3의 변수들과 그들의 변화율	57.95%	43.40%	61.04%
Table 4의 변수들	60.91%	40.93%	63.13%

Table 4의 변수들과 그들의 변화율	59.93%	41.80%	66.46%
	Bagging + Decision Tree	Bagging + Naïve Bayesian	Bagging+ RandomForest
Table 3의 변수들	61.51%	41.67%	62.39%
Table 3의 변수들과 그들의 변화율	61.9%	47.1%	63.87%
Table 4의 변수들	62.76%	47.1%	65.72%
Table 4의 변수들과 그들의 변화율	64.98%	41.8%	67.32%

두 번째 실험에서의 결과로, Table 6에 나타나 있는 15개의 변수들이 선정되었다. 기존논문에서 쓰인 주요 재무변수 중 본 연구에서 선정된 32개의 후보변수들 중에서, wrapper 방식에 backward elimination 기법을 사용하여 가장 높은 예측정확도를 보이는 모델을 구축할 때 사용되는 최종 주요변수를 선정하였다. 15개의 재무변수 (Table 6)를 사용하였을 때 앙상블(Bagging+ RandomForest) 기법의 예측정확도가 73.86%로 가장 높다는 것을 확인할 수 있었다 (Table 7 참조).

Table 6 – financial variables for credit rating

Variables	Items	Definition
X1	Size	Total assets in natural log
X2	Financial Structure	Net assets/ total debt
X3	Financial Structure	Quick ratio
X6	Profitability	Return on equities
X7	Profitability	Earnings per share
X10	Leverage	Debt ratio
X11	Leverage	LT debt/Net assets
X13	Leverage	Retained earnings/total assets
X14	Leverage	Long-term debt leverage ratio
X16	Solvency	Equity/total assets
X19	Solvency	(Current assets-Inventory)/ Current liabilities
X21	Solvency	Interest coverage ratio
X22	Management ability	Inventory turnover ratio
X27	Liquidity	Current ratio
X32	Cash	Cash flow from operating activity

Table 7 – Accuracy of the second experiment

	Decision Tree	NaïveBayesian	RandomForest
Accuracy	64.86%	52.16%	66.58%
	Bagging+ Decision Tree	Bagging+ NaïveBayesian	Bagging+ RandomForest
Accuracy	69.05%	54.50%	<u>73.86%</u>

세 번째 실험으로 앞에서 선정한 15개의 최종 재무변수와 이들의 2년간의 변화율 변수를 사용하여 다양한 알고리즘 기법을 적용한 결과 Table 8과 같이 Bagging+ RandomForest 앙상블기법이 Decision tree(J48), NaïveBayesian을 적용했을 때 보다 예측정확도(77.56%)가 높았으며, 또한 이는 두 번째 실험에서의 예측정확도(73.86%) 보다 더욱 높은 것을 확인할 수 있었다.

Table 8 – Accuracy of the third experiment

	Decision Tree	NaïveBayesian	RandomForest
Accuracy	64.98%	48.34%	71.52%
	Bagging+ Decision Tree	Bagging+ NaïveBayesian	Bagging+ RandomForest
Accuracy	73.24%	52.28%	77.56%

## Conclusion

본 연구에서는 기업신용평가에서의 중요한 영향을 미치는 주요재무변수의 선정과 그 변화율 적용에 관한 실험을 진행하였다.

결과적으로, 재무변수들의 변화율 적용이 긍정적으로 쓰일 수 있다는 점과, 15개의 주요 재무변수를 선정하여 그들의 2년간의 변화율 적용이 기업신용평가 예측에 유익하게 사용될 수 있음을 확인할 수 있었다.

이번 연구에서는 S&P로부터 신용등급을 받은 북미지역에 있는 1,158개 기업들의 3년간의 재무변수와 신용등급을 사용하였는데, 지난 몇 년간의 재무데이터를 사용하는 것이 가장 좋은 예측정확도를 보이게 되는지 차후에 연구해 보는 것도 흥미 있는 일일 것이다.

## References

- [1] D. Niklis, M. Doumpos and C. Zopounidis (2014). “Combining market and accounting-based models for credit scoring using a classification scheme based on support vector machines” *Applied Mathematics and Computation* 234 (2014) 69–81
- [2] H. Zhong, C. Miao, Z. Shen, and Y. Feng (2014). “Comparing the learning effectiveness of BP, ELM, I-ELM, and Svm for corporate credit ratings” *Neurocomputing* 128 (2014) 285–295
- [3] Kim, K.-J. and H. Ahn (2012). “A corporate credit rating model using multi-class support vector machines with an ordinal pairwise partitioning approach” *Computers & Operations Research* 39(8): 1800-1811
- [4] H. Ogut, M. Doganay, N. Ceylan, and R. Akta (2012). “Prediction of bank financial strength ratings: The case of Turkey” *Economic Modelling* 29 (2012) 632-640
- [5] Chen, Y.-S. and C.-H. Cheng (2012). “Hybrid models based on rough set classifiers for setting credit rating decision rules in the global banking industry” *Knowledge-Based Systems* 39(1): 224-239
- [6] Huang, Z., Chen, H., Hsu, C.-J., Chen, W.-H., and Wu, S. (2004). “Credit rating analysis with support vector machines and neural networks: a market comparative study” *Decision Support Systems* 37(4): 543-558
- [7] Yeh, C.-C., Lin, F., and Hsu, C.-Y. (2012). “A hybrid KMV model, random forests and rough set theory approach for credit rating” *Knowledge-Based Systems* 33(4): 166-172
- [8] Y. Na and DM Jin. (2003). “On the Usefulness of Financial Information in Forecasting of Credit Ratings: Post IMF” *Journal of Accounting Information Research*, vol. 21
- [9] Lee, BG and Lee, HS. (2004). “A study on the Relevance of Credit Rating Changes and Accounting Information” *Journal of Accounting Research*, vol. 9